



控制理论与应用
Control Theory & Applications
ISSN 1000-8152, CN 44-1240/TP

《控制理论与应用》网络首发论文

题目：基于 ISCNN-LightGBM 的轴承故障诊断
作者：张思源，纪洪泉，刘洋
收稿日期：2021-12-14
网络首发日期：2022-05-06
引用格式：张思源，纪洪泉，刘洋. 基于 ISCNN-LightGBM 的轴承故障诊断[J/OL]. 控制理论与应用.
<https://kns.cnki.net/kcms/detail/44.1240.tp.20220429.1809.080.html>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于ISCNN-LightGBM的轴承故障诊断

张思源¹, 纪洪泉¹, 刘 洋^{2†}

(1. 山东科技大学 电气与自动化工程学院, 山东 青岛 266000;

2. 拉夫堡大学 航空与汽车工程系, 英国 拉夫堡 LE113TU)

摘要: 在传统卷积神经网络与分类器相结合的故障诊断方法中, CNN用于故障特征提取时, 存在着提取的特征质量不高与运行时间较长的问题. 针对以上问题, 本文提出了一种基于改进单层卷积神经网络及LightGBM的故障诊断模型. 该模型通过将特征距离函数嵌入CNN的损失函数中, 提升了CNN特征提取的能力, 增强了CNN与后续分类器之间的联系, 从而提升了整体模型的故障诊断能力. 于此同时, 经过改进的单层的卷积神经网络进一步缩短了模型运行的时间, 提升了模型的诊断效率. 通过对两个不同的公共数据集进行对比实验, 其结果表明, 本文所提诊断模型对多种轴承故障的诊断准确率与诊断效率显著高于其他诊断模型.

关键词: 故障诊断; 滚动轴承; 深度学习; 单层卷积神经网络; 轻量级梯度提升机

引用格式: 张思源, 纪洪泉, 刘洋. 基于ISCNN-LightGBM的轴承故障诊断. 控制理论与应用, 2022, 39.

DOI: 10.7641/CTA.2022.11222

Bearing fault diagnosis based on ISCNN-LightGBM

ZHANG Si-yuan¹, JI Hong-quan¹, LIU Yang^{2†}

(1. College of Electrical Engineering and Automation, Shandong University of Science and Technology, Qingdao Shandong 266000, China;

2. Department of Aeronautical and Automotive Engineering, Loughborough University, Loughborough LE113TU, England)

Abstract: In traditional fault diagnosis methods combining convolutional neural network (CNN) and classifier, there are problems of low-quality features and long-running time when CNN is used to extract fault features. In this paper, to solve the above problems, a fault diagnosis model based on an improved single-layer convolutional neural network and LightGBM is established. By embedding the feature distance function into the loss function of CNN, the model improves the ability of CNN feature extraction and enhances the connection between CNN and subsequent classifiers, thereby improving the fault diagnosis ability of the overall model. At the same time, the improved single-layer convolutional neural network further shortens the running time of the model and improves its diagnostic efficiency of the model. Through comparative experiments on two different public data sets, the results show that the diagnostic accuracy and efficiency of the proposed model are significantly higher than that of other diagnostic models for various bearing faults.

Key words: fault diagnosis; rolling bearing; deep learning; single-layer convolutional neural network; LightGBM

Citation: ZHANG Siyuan, JI Hongquan, LIU Yang. Bearing fault diagnosis based on ISCNN-LightGBM. *Control Theory & Applications*, 2022, 39.

1 引言

随着科学技术的不断发展, 旋转机械智能化与自动化以及重载化的趋势愈加明显. 由于旋转机械规模的逐渐扩大以及极端恶劣的工作环境, 导致其非正常运行的因素也愈加复杂. 轴承作为旋转机械系统的主要组成部分, 其自身易损的特性是导致机械故障的主要原因之一^[1]. 针对轴承进行及时精准的故障诊断,

是保证整个机械系统正常运行的关键^[2].

作为轴承故障诊断方法之一, 基于深度学习理论的故障诊断方法近些年受到了越来越多的关注^[3-6]. 卷积神经网络(Convolutional Neural Network, CNN)作为深度学习理论中最具有代表性的算法之一, 在保证一定的故障诊断精准度的基础上, 可以自适应地进行特征提取, 为轴承的故障诊断提供了巨大的帮

收稿日期: 2021-12-14; 录用日期: 2022-04-30.

[†]通信作者. E-mail: y.liu6@lboro.ac.uk; Tel.: +86 0532-86058179.

本文责任编辑: 周东华.

山东省自然科学基金(ZR2019BF021), 国家自然科学基金(61803232)资助.

Supported by the Natural Science Foundation of Shandong Province (ZR2019BF021) and the National Natural Science Foundation of China (61803232).

助^[7]. 文献[8]最早将CNN用于旋转机械的故障诊断, 其诊断精准度相比较于传统的故障诊断方法有较大的提升. 文献[9]将一维振动信号数据转化为二维灰度图像作为输入, 利用CNN进行轴承的故障诊断, 取得了较高的分类精度. 文献[10]则通过将多个传感器的振动信号转换为图像, 得到比单个传感器振动信号更加丰富的特征, 从而进一步提升了CNN故障诊断的精准度. 虽然CNN用于轴承的故障诊断较于传统诊断方法有着明显的优势, 但仍然存在着由于自身结构的复杂性导致的诊断时间过长^[11]以及结构中的softmax分类器易陷入局部最优^[12]等问题.

为解决分类精准度的问题, 一些学者提出了将CNN与传统机器学习相结合的故障诊断方法, 旨在提高算法的精准度与鲁棒性. 文献[13]将CNN自动提取特征的能力与K最近邻(K Nearest Neighbor, KNN)简单高效的优势相结合, 提升了传统CNN的诊断精度. 文献[14]则将CNN与支持向量机(Support Vector Machine, SVM)算法相结合, 在提升了诊断精度的同时也增强了诊断模型的鲁棒性. 文献[15]通过将CNN与轻量级梯度提升机(Light Gradient Boosting Machine, LightGBM)相结合, 进一步提升了故障诊断的能力, 缩短了故障诊断的时间.

以上将CNN与传统机器学习相结合的故障诊断方法, 主要是利用了CNN可以自动提取特征的特点. 对于大量的原始数据, 相较于传统人工特征提取, CNN可以对不同数据进行自适应的特征提取, 从而避免了人工特征提取的不足, 提高了诊断模型的诊断效率. 但由于大量的机器学习算法对于数据特征有着很强的依赖性, 即CNN提取的数据特征的优良对诊断效果的好坏有着巨大影响. 与此同时, 由于CNN自身的结构较为复杂, 也导致了特征提取过程的时间过长. 针对上述问题, 本文提出了一种基于改进单层卷积神经网络及LightGBM(Improved Single-layer Convolutional Neural Network and LightGBM, ISCNN-LightGBM)的轴承故障诊断方法.

ISCNN-LightGBM仅使用了一层卷积层, 很大程度上减少了CNN的参数数量, 缩短了特征提取的时间. 同时, 相较于其他机器学习方法, LightGBM由于自身的结构优势, 在保证分类精准度的条件下极大地缩短了运行的时间, 较大程度地提高了故障诊断的效率. 本文通过将特征距离(Feature Distance)^[16]函数嵌入CNN中, 使得CNN提取到的特征不仅较大程度的保留了原数据的信息, 并进一步突出了数据自身的特点, 对总体的故障诊断性能进行了改善. 本文利用不同的公开数据集, 通过对其他不同诊断模型进行对比分析, 验证了特征距离函数对于提取特征质量的提升以及本文所提诊断模型的有效性与普适性.

2 背景知识介绍

2.1 CNN原理简介

卷积神经网络是一种前馈神经网络, 主要由输入层, 隐藏层与输出层三部分组成. 隐藏层中包含卷积层, 全连接层与池化层, 其中卷积层是整个网络的核心.

卷积层的作用是将原有数据信息进行重组过滤, 构建输入数据的特征空间. 卷积层通过不同的卷积核提取多种特征, 它承担了网络的大部分计算工作. 由于卷积层拥有局部感知和参数共享的特点, 在一定程度上减少了网络的计算量, 降低了网络的复杂性. 卷积层的公式描述如下:

$$\begin{aligned} a^{l(i',j')} &= K_n^l \times X^{l(i',j')} \\ &= \sum_{i=0}^{h-1} \sum_{j=0}^{w-1} k_n^{l(i,j)} \times x^{l(i'+i,j'+j)}, \end{aligned} \quad (1)$$

式中: K_n^l 为第 l 层第 n 个卷积核的权值; $X^{l(i',j')}$ 为第 l 层的输入区域, 其中 i' 与 j' 为输入的起始点位置; h 与 w 为第 l 层第 n 个卷积核的高度与宽度; $k_n^{l(i,j)}$ 为第 l 层第 n 个卷积核的第 (i,j) 个的值; $x^{l(i'+i,j'+j)}$ 为输入区域的第 $(i'+i,j'+j)$ 个的值; $a^{l(i',j')}$ 为当前输入数据卷积后的输出值.

为实现对于非线性模型的较好拟合, 卷积网络在卷积层后引入了非线性的激活函数. 常用的激活函数包 括tanh, sigmoid, ReLU 和LeakReLU. 本文 采用LeakReLU 函数, 其公式描述如下:

$$\begin{aligned} y^{l(i',j')} &= \max(0, a^{l(i',j')}) + \\ &\quad leak \times \min(0, a^{l(i',j')}), \end{aligned} \quad (2)$$

式中: $leak$ 为一个很小的常数, $y^{l(i',j')}$ 为LeakReLU激活函数的输出.

池化层的作用是降低数据维度, 提取突出的数据特征, 通过对数据的欠采样来重构数据的大小, 又被称为欠采样层. 常用的池化方式包括平均池化和最大池化, 其中平均池化的公式描述如下:

$$p^{l(i',j')} = \frac{1}{w' + h'} \sum_{i'=0}^{w'-1} \sum_{j'=0}^{h'-1} y^{l(i',j')}, \quad (3)$$

式中: w' 和 h' 为池化层的宽度和高度; $p^{l(i',j')}$ 为池化后的输出.

在使用传统CNN进行特征提取的过程中, 通常使用全连接层将卷积层提取到的特征进行特征融合, 作为最终提取到的数据特征. 但由于全连接层的特点, 其参数量会十分庞大, 这将会导致诊断模型的速度下降, 并且容易引起诊断模型的过拟合. 为了提升诊断模型的效率, 减少模型的参数, 本文引入了全局平均池化层(Global Average Pooling, GAP)^[17]代替全连接层, 即使用全局平均池化层后的输出作为CNN提取到

的数据特征. 全局平均池化通过对卷积层输出的特征图求平均值, 将每个特征图简化为单独的一个特征值. 该过程中并不会产生新的参数, 从而减少了模型的复杂度, 提高了诊断模型的抗干扰性.

2.2 LightGBM原理简介

LightGBM是梯度提升树(Gradient Boosting Decision Tree, GBDT)算法的一种实现, 是一种基于决策树的集成学习方法. 2016年微软的DMTK团队首次提出LightGBM算法, 该算法具有训练速度快, 准确率高等优点, 并且可以满足大规模数据处理的需求.

GBDT算法是boosting算法中的一种代表性算法. 该算法的每次迭代都会在之前生成的所有学习器的基础上生成一个新的学习器, 然后使用梯度下降的方法使损失函数逐渐减小, 最终得到一个最好的学习器用作预测模型.

假设训练样本集为 $D = [(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)]$. 并假设学习器迭代次数为 T , 样本 i 的损失函数表示为 $L(y_i, f(x_i))$, 学习器的输出为 $f(x)$. GBDT的主要算法步骤如下:

- 1) 初始化学习器. 学习器的输出为 $f_0(x)$.

$$f_0(x) = \arg \min_c \sum_{i=1}^n L(y_i, c). \quad (4)$$

- 2) 进行迭代. 迭代次数为 $t = 1, 2, 3, \dots, T$.

- 计算负梯度 r_{ti} .

$$r_{ti} = - \left[\frac{\partial L(y_i, f(x_i))}{\partial f(x_i)} \right] f(x) = f_{t-1}(x). \quad (5)$$

- 通过回归树对值 (x_i, r_{ti}) 的拟合, 可以得到 t 棵新的回归树. 对于这些新生成的回归树, 叶节点的数据集为 R_{tj} , 其中 $j = 1, 2, 3, \dots, J$, J 为叶结点的个数. 计算其最佳拟合值 c_{tj} .

$$c_{tj} = \arg \min_c \sum_{x_i \in R_{tj}} L(y_i, f_{t-1}(x) + c). \quad (6)$$

- 更新学习器, 输出为 $f_t(x)$.

$$f_t(x) = f_{t-1}(x) + \sum_{j=1}^J c_{tj} I(x \in R_{tj}). \quad (7)$$

- 3) 得到最终的学习器, 输出为 $f(x)$.

$$f(x) = f_T(x) = f_0(x) + \sum_{t=1}^T \sum_{j=1}^J c_{tj} I(x \in R_{tj}). \quad (8)$$

尽管GBDT具有较好的模型结构, 在某些情况下表现出了优异的性能, 但它仍然存在一些不可避免的

缺点. 例如, 当处理的数据具有高维数和数量较多时, 通常需要花费较长的时间, 从而降低了诊断效率^[18]. 针对上述问题, LightGBM使用了基于梯度的单边采样(Gradient-based One-Side Sampling, GOSS)和互斥特征捆(Exclusive Feature Bundling, EFB)两种新的方法.

GOSS用于对训练数据的有选择地采样, 通过抛弃一些对最终计算影响较小的样本, 较大程度地提升了计算效率. 为了保证原有样本的总体分布, 在随机丢弃部分信息增益较小的数据的同时, 对于留下的该类样本需乘以一个常数. 具体来说, GOSS首先根据信息增益大小对样本进行排序, 并选择前 $a \times 100\%$ 贡献较大的样本. 然后, 从剩余的样本随机抽取 $b \times 100\%$ 的样本, 并将这些样本的信息增益乘以一个大小为 $\frac{1-a}{b}$ 的常数值. 通过以上的操作, 可以将算法注意力放在那些缺乏训练的样本上, 而不改变原始的数据分布.

EFB可以减少输入数据的特征数量而不牺牲算法的精准度. 一般实际应用的数据虽然具有较高的数据维度, 但同时也具有稀疏性的特点. EFB提出了冲突比这个概念来量化不同特征的互斥性, 通过特征的冲突比的大小来决定是否对不同的特征进行捆绑. EFB通过将具有较小冲突比的不同特征捆为一个特征, 在尽可能保留原有特征信息的基础上, 很大程度上减少数据的特征数量, 提高了算法的效率.

除此之外, LightGBM使用直方图(histogram)方法减少数据分割次数, 增强了算法的泛化能力; 采用带深度限制的按叶生长策略(Leaf-wise Tree Growth)降低了算法的误差, 得到了更好的精确度. 以上两种方法都为减少算法的运行时间做出了较大的贡献.

3 所提方法

利用上文所介绍的背景知识后, 本文搭建了基于深度学习与传统机器学习相结合的故障诊断模型. 并且, 通过在模型中嵌入特征距离函数提升了该模型的故障诊断的效果. 下文将详细介绍该模型的具体结构.

3.1 特征距离

在传统的基于机器学习的故障诊断方法中, 对原始数据进行人为的特征提取是故障诊断中比较重要的一个环节. 提取的特征中包含的有用信息决定了机器学习方法性能的上界. 如果提取的特征能够较大程度的保留当前类别样本的信息并且异于其他类别的样本特征, 则说明该特征具有较高的质量, 有利于分类器的训练, 否则较低的特征质量会使分类器的分类效果变差. 相较于传统的机器学习方法, 深度学习方法并不需要人工提取特征, 其自身可以通过神经网络的迭代对样本的特征进行深度挖掘, 自适应地提取数据特征.

基于深度学习与传统机器学习相结合的故障诊断方法, 样本数据会首先经过神经网络进行特征提取, 之后再提取到的数据特征送入分类器中, 得到最终诊断结果。

通过上述分析可以看出, CNN作为深度学习方法的一种, 较于传统方法有着明显的优势. 但由于CNN的结构特点, 提取的特征更多的依赖于其自身的分类效果, 与之后的分类器的联系较弱. 为了建立起CNN与传统机器学习算法之间的联系, 使得CNN提取的特征更加的有利于分类器的训练, 本文受文献[16]启发, 引入了特征距离的概念。

特征距离函数通过最小化同类别样本之间的特征距离, 最大化不同类别样本间的特征距离, 使得提取到的特征质量得到了提升。

同类样本间的距离表示为 d_k , 公式描述如下:

$$d_k = \frac{1}{N_k} \sum_{i=1}^{N_k} \|f_i^k - m^k\|^2, \quad (9)$$

式中: N_k 为第 k 类样本所提取特征的个数; f_i^k 为第 k 类第 i 个样本提取的特征; $m^k = \frac{1}{N_k} \sum_{i=1}^{N_k} f_i^k$ 为 k 类样本所提取特征的均值特征。

不同类别样本间的特征距离表示为, 公式描述如下:

$$d_{kk'} = \frac{N_k + N_{k'}}{(K-1)N} \|m^k - m^{k'}\|^2, \quad (10)$$

式中: K 为类别数, $k, k' \in K$; N 为各类样本总数。

根据 d_k 和 $d_{kk'}$ 构造特征距离函数 L_{FD} . 针对于该函数结构, 考虑到函数形式的统一与计算复杂度, 本文选择使用加减的构造形式. 其公式描述如下:

$$L_{FD}(f) = \sum_{k=1}^K d_k - \sum_{k=1}^{K-1} \sum_{k'=k+1}^K d_{kk'} + \xi \|f\|^2, \quad (11)$$

式中: f 为样本提取的所有特征; $\|f\|^2$ 为防止寻优问题非凸所添加的正则项; ξ 为权重系数。

3.2 ISCNN-LightGBM

本文使用结构如图1所示含有全局平均池化层的CNN(GAP-CNN)模型. 根据数据融合的方法, 使用两个不同位置的加速度传感器采集的振动信号作为模型的输入. 为了提高模型的泛化能力和模型的稳定性, 在二维的振动信号输入卷积层之前, 对其进行了概率为0.2的随机失活处理. 卷积层由64个大小相同的卷积核构成, 分别提取原数据的多个维度的不同特征, 可得到64个不同的特征图. 全局平均池化层对每个特征图进行全局平均池化, 从而得到了原始数据的64个特征值. Flatten层将不同的特征值进行维度上的统一, 并送入到输出层。




图1 GAP-CNN模型

Fig. 1 GAP-CNN model

输出层使用softmax函数作为激活函数, 其公式描述如下:

$$\bar{y}_i = \frac{e^{a_i}}{\sum_{j=1}^J e^{a_j}}, \quad (12)$$

式中: a_i 为第 i 个输出节点的线性部分的输出; J 为输出节点的个数, 同时也为分类类别数; \bar{y}_i 为输出节点的最终输出值。

故障诊断问题为多分类问题, 本文使用交叉熵作为损失函数, 公式描述如下:

$$J_{GAP-CNN} = -\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K y_i^k \log(\bar{y}_i^k), \quad (13)$$

式中: N 为样本的总数, K 为类别数; 当样本属于当前类别时, y_i^k 为1, 否则为0; \bar{y}_i^k 为输出层的不同节点的输出值。

ISCNN模型的损失函数公式描述如下:

$$J_{ISCNN} = -\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K y_i^k \log(\bar{y}_i^k) + \eta L_{FD}, \quad (14)$$

式中: 由式(6)可知 $L_{FD} = L_{FD}(f)$; η 为权重系数。

本文所提出的改进单层神经网络模型不同于传统GAP-CNN模型, 为提高提取特征的质量, 该模型在GAP-CNN模型Flatten层后嵌入了特征距离函数. 其结构如图2所示。

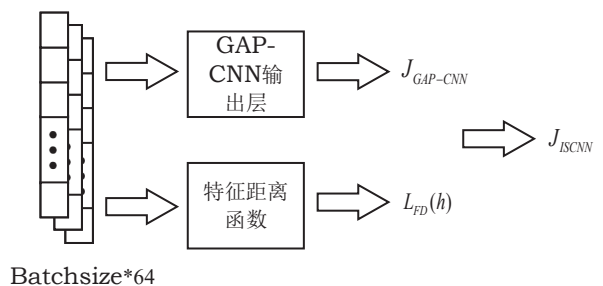


图2 ISCNN模型

Fig. 2 ISCNN model

为提升分类的精准度, ISCNN-LightGBM诊断模型将在ISCNN的全局平均层提取到的特征送入LightGBM进行分类, 从而得到最终诊断结果. 诊断模型具体流程如图3所示.

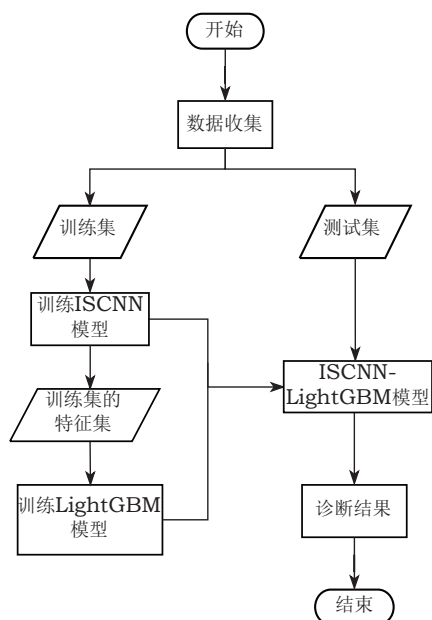


图3 ISCNN-LightGBM诊断模型流程图

Fig. 3 Flowchart of the ISCNN-LightGBM diagnostic model

4 仿真与结果分析

本文主要使用自美国凯斯西储大学(CWRU)轴承数据中心的轴承数据, 对所提方法进行实验研究. 为进一步验证本文所提方法的普适性与通用性, 本文使用来自德国Paderborn大学的轴承数据集作为补充实验.

4.1 CWRU轴承数据

4.1.1 数据集简介

如图4所示, 该试验仿真平台由一台2马力(1.5kW)电机, 扭矩传感器, 功率测试仪和电子控制器组成. 电动机风扇端和驱动端的轴承座上方各放置一个加速度传感器用来采集故障轴承的振动信号.




图4 CWRU实验平台^[19]

Fig. 4 CWRU experimental platform^[19]

CWRU采用电火花加工工艺对电机轴承进行故障设置. 在不同负载下, 故障类型分别为钢球故障, 内圈故障, 外圈故障, 每种故障类型又存在着不同的故障程度.

本研究选用负载为1马力, 频率为48kHz下采集的数据, 100个采样点作为一个样本. 选取70%的故障数据为训练数据, 30%的数据为测试数据. 故障类型与样本数量如表1所示.

表1 CWRU轴承数据

Table 1 CWRU bearing data

轴承状态	故障直径/mm	样本数量	标签
正常	0	2673/1143	0
钢球故障	0.178	2673/1143	1
	0.356	2673/1143	2
	0.534	2673/1143	3
内圈故障	0.178	2673/1143	4
	0.356	2673/1143	5
	0.534	2673/1143	6
外圈故障	0.178	2673/1143	7
	0.356	2673/1143	8
	0.534	2673/1143	9

4.1.2 模型验证

本文所提出的ISCNN-LightGBM诊断模型可分为两个部分, ISCNN用于特征提取, LightGBM用于最终的故障诊断. 其中ISCNN神经网络部分参数如图1所示, LightGBM采用默认参数, 其余参数如表2所示.

表2 模型参数

Table 2 Model parameters

参数	参数值
Mini-Batch	30
学习率(ISCNN)	0.0001
优化器	Adam
η	0.01
ξ	0.1

通过对ISCNN-LightGBM进行如上参数设置, 利用选取的数据对模型进行训练和测试, 神经网络迭代次数设置为400次. 由于神经网络权重的初始值是随机的, 为保证实验结果的可靠性与稳定性, 每种模型进行了10次的训练和测试.

为检验ISCNN-LightGBM诊断模型有效性和特征提取能力的优越性, 构建传统CNN-LightGBM诊断模型. 该模型按照传统CNN结构, 在Flatten层后加入一层全连接层用于特征融合, 其他部分网络结构和训练参数均与ISCNN-LightGBM模型保持一致. 每种诊断模型通过10次的训练, 分别得到10个诊断模型. 利用测试集分别对这些模型进行测试, 图5为各模型测试结果的平均值.

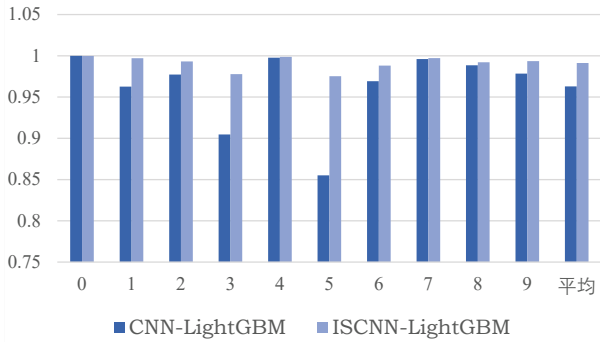


图5 CNN-LightGBM与ISCINN-LightGBM的故障诊断精准度

Fig. 5 Fault diagnosis accuracy of CNN-LightGBM and ISCINN-LightGBM

图5中横轴为故障类型,纵轴为诊断精准度。由图5可知,在负载为1马力下对轴承的不同故障进行诊断,ISCINN-LightGBM平均诊断精准度达到了99.13%。其中,标签为0的故障样本的诊断精准度达到了100%。虽然模型对标签为5的故障样本诊断效果最差,但诊断精准度仍然达到了97.53%。由此可知,ISCINN-LightGBM诊断模型可以较好的完成多种轴承故障的诊断。通过对比不难发现,ISCINN-LightGBM诊断模型对每种故障的诊断精准度几乎都高于传统CNN-LightGBM诊断模型。对于标签为3和标签为5的故障样本,相较于传统CNN-LightGBM诊断模型,ISCINN-LightGBM诊断模型诊断精准度分别提高了7.31%和12.03%。由此可知,ISCINN-LightGBM诊断模型的故障诊断能力整体优于传统CNN-LightGBM诊断模型。并且对于部分故障的诊断,ISCINN-LightGBM诊断模型有着显著的优势。

为验证ISCINN-LightGBM诊断模型的普适性,本文同时选择了负载为2马力和3马力的工作条件进行了同等测试。并且为了说明LightGBM分类器的优越性,本文选择了其他几种传统的分类算法作为对比。这些分类算法包括SVM, KNN和随机森林(Random Forest, RF),其参数均使用默认参数。同样对各模型进行10次的训练与测试,最终结果为10次测试的平均值。表3为上述模型在不同负载下的故障诊断精准度平均值,表4则为故障诊断精准度标准差。

由表3可知,无论在何种负载下,ISCINN-LightGBM诊断模型都有着最高的故障诊断精准度。通过表4可以看出,ISCINN-LightGBM诊断模型有着较小的诊断精准度标准差,因此该模型存在着较强的稳定性。由以上分析可知,ISCINN-LightGBM诊断模型有着较满意的普适性,在不同负载上都能达到较高的诊断精准度和较为稳定的诊断性能。通过CNN诊断模型与CNN-LightGBM诊断模型进行对比,不难看出,使用LightGBM作为分类

器确实对模型的故障诊断能力有所提升。

表3 不同模型在不同负载下的故障诊断精准度平均值/%

Table 3 Average accuracy of fault diagnosis for different models under different loads/%

负载	1马力	2马力	3马力
CNN	95.27	95.68	97.93
CNN-LightGBM	96.30	96.71	98.22
ISCINN-SVM	99.01	98.21	98.59
ISCINN-RF	98.33	97.33	98.06
ISCINN-KNN	98.28	97.21	97.36
ISCINN-LightGBM	99.13	98.58	98.82

表4 不同模型在不同负载下的故障诊断精准度标准差/%

Table 4 Standard deviation of fault diagnosis accuracy of different models under different loads/%

负载	1马力	2马力	3马力
CNN	0.2267	0.1911	0.0577
CNN-LightGBM	0.2090	0.1253	0.0910
ISCINN-SVM	0.0513	0.2247	0.14319
ISCINN-RF	0.0850	0.1296	0.1474
ISCINN-KNN	0.1063	0.1820	0.1975
ISCINN-LightGBM	0.0438	0.0987	0.0789

表5 不同诊断模型平均诊断时间/s

Table 5 Average diagnosis time of different diagnostic models/s

负载	1马力	2马力	3马力
CNN	0.2739	0.2817	0.2817
CNN-LightGBM	0.2878	0.3060	0.2926
ISCINN-SVM	2.7649	2.9034	2.8973
ISCINN-RF	0.3556	0.3504	0.3525
ISCINN-KNN	7.8824	6.8709	7.1805
ISCINN-LightGBM	0.2961	0.2885	0.2909

由表3与表4可以看出,对于改进的诊断模型,使用LightGBM作为分类器无论在何种负载下,故障诊断精准度均高于其他三种分类器,并且模型也最为稳定。其中ISCINN-SVM诊断模型有着与ISCINN-LightGBM诊断模型最为接近的诊断性能,但通过表5可以看出,ISCINN-SVM诊断模型的平均诊断时间是ISCINN-LightGBM诊断模型的10倍左右。相对于CNN-LightGBM而言,ISCINN-LightGBM的结构由于特征距离函数的嵌入而变得复杂,从而导致其诊断速度并未得到明显提升。而KNN则由于自身结构与对输入特征数量的敏感性,导致ISCINN-KNN诊断模型的平均诊断时间长于其他模型。由上述可知,

ISCNN-LightGBM诊断模型较于本文提到其他诊断模型, 对轴承的故障诊断存在着显著的优势。

4.2 Paderborn轴承数据

4.2.1 数据集简介

对于轴承的故障诊断所使用的数据集, 多数来自于设备平台上的不同加速度传感器所采集振动信号。其主要依据为, 在设备运行时不同的轴承故障会较为清晰的反映在其振动信号上。因此, 使用加速传感器所采集的振动信号对不同轴承故障的进行诊断似乎比较合理。但不同于实验平台, 在实际工厂应用中, 针对不同的设备安装加速度传感器会存在一定的操作困难并造成使用和维护成本的增加^[20]。Paderborn轴承数据集提供了不同轴承故障的驱动系统电机的电流信号数据。通过利用该数据, 不需要额外的传感器, 即可完成对安装在驱动系统但在电机之外的外部轴承的故障诊断。

本研究选用驱动系统的转速为1500rpm, 负载扭矩为 $M = 0.7 \text{ Nm}$, 径向力为 $F = 1000 \text{ N}$ 工作状态下的驱动电机电流数据。同样设置100个采样点为一个样本点, 其样本个数与故障类型如表6所示。

表 6 Paderborn轴承数据

Table 6 Paderborn bearing data

轴承状态	数据来源	样本数量	标签
正常	K001	5373/2304	0
内圈故障	KA05	5373/2304	1
外圈故障	KI05	5373/2304	2

4.2.2 模型验证

为保证本文所提方法的普适性, 本研究使用与CWRU轴承数据相同的模型对其进行验证。并同样为每种模型进行了10次验证, 保证了模型的稳定性。图6为10次实验诊断精确度的平均值。

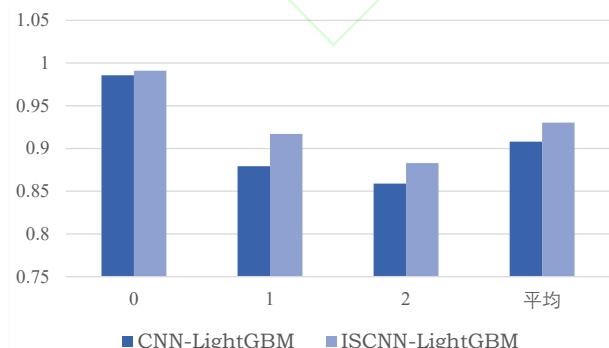


图 6 CNN-LightGBM与ISCNN-LightGBM的故障诊断精度

Fig. 6 Fault diagnosis accuracy of CNN-LightGBM and ISCNN-LightGBM

图6横轴为故障类型, 纵轴为诊断精度。由图6可知, 无论何种轴承故障类型, ISCNN-LightGBM的诊

断精度都要高于传统的CNN-LightGBM的诊断精度。ISCNN-LightGBM对所有故障的平均诊断精度为93.03%, 显著高于传统的CNN-LightGBM诊断模型的诊断精度, 进一步验证了本文所提方法对于传统的CNN-LightGBM的诊断模型的故障诊断能力的提升。

为了说明LightGBM分类器的优越性, 本研究同样与其他几种传统的分类算法进行了对比。表7为不同故障模型的故障诊断精度平均值与故障诊断精度标准差之间的对比。

表 7 不同诊断模型对比%

Table 7 Comparison of different diagnostic models%

诊断模型	诊断精度平均值	诊断精度标准差
CNN	79.84	1.2766
CNN-LightGBM	90.80	0.4725
ISCNN-SVM	91.81	1.8222
ISCNN-RF	92.09	0.5164
ISCNN-KNN	91.58	1.6132
ISCNN-LightGBM	93.04	0.4411

由表7可知, 传统CNN的平均诊断精度为79.84%, 相较于使用CWRU轴承数据的诊断精度有着大幅度下降。其原因在于本研使用驱动电机的电流信号作为输入, 其信号数据故障特征相较于振动信号不明显, 因此造成了故障诊断效果的下降。与此同时, ISCNN-LightGBM的诊断精度的相较于传统CNN的诊断精度有着十分明显的提升。并且, 同其他模型相比, ISCNN-LightGBM有着最高的诊断精度平均值和最小的诊断精度标准差, 再次验证了本文所提方法存在着较为优秀的诊断精度与较为稳定的诊断性能。

5 结论

本文提出了一种基于ISCNN-LightGBM诊断模型的轴承故障诊断方法, 该模型融合了改进卷积神经网络和LightGBM模型各自的优点, 实现了对多种轴承故障的精确诊断。相较于传统CNN-LightGBM诊断模型的故障诊断方法, 该模型通过在神经网络中嵌入特征距离函数提升了提取的特征的质量, 使其更有利于后续分类器的训练, 从而改善了模型故障诊断的能力。ISCNN-LightGBM诊断模型神经网络部分仅使用了一层卷积层, 极大地减少了模型的参数数量, 缩短了模型的诊断时间。实验结果表明ISCNN-LightGBM诊断模型能够对轴承的多种故障进行有效的诊断, 并且通过对模型的多次训练和检测验证了该模型的稳定性与普适性, 以及通过对比试验说明了该模型在轴承故障诊断方面的优越性。

在基于数据的故障诊断的过程中, 对于原始数据的特征提取是较为关键的一步, 特征数据的质量影响

着整个诊断模型的故障诊断能力. 数据特征自动提取的方法除本文所研究的CNN外, 还存在着其他有着优秀特征提取能力的算法, 如: 深度卷积自编码器(Deep Convolutional Auto-Encoders, DCAE)^[21], 卷积深度置信网络(Convolutional Deep Belief Networks, CDBN)^[22]及半监督图卷积深度置信网络(Semi-Supervised Graph Convolution Deep Belief Network, SSGCDBN)^[23]等. 今后我们将会针对此类算法, 从多个方面, 继续加深对轴承故障诊断的研究.

参考文献:

- [1] JIGYASU R, SHARMA A, MATHEW L, et al. A review of condition monitoring and fault diagnosis methods for induction motor. *Second International Conference on Intelligent Computing and Control Systems (ICICCS)*, IEEE, 2018, 1713-1721.
- [2] LIU Jianchang, QUAN He, YU Xia, et al. Rolling bearing fault diagnosis based on parameter optimization VMD and sample entropy. *Acta Automatica Sinica*, 2019, 1-12. <https://doi.org/10.16383/j.aas.190345>.
(刘建昌, 权贺, 于霞, 等. 基于参数优化VMD和样本熵的滚动轴承故障诊断. *自动化学报*, 2019, 1-12. <https://doi.org/10.16383/j.aas.190345>.)
- [3] ZHANG J Q, SUN Y, GUO L, et al. A new bearing fault diagnosis method based on modified convolutional neural networks. *Chinese Journal of Aeronautics*, 2020, 33(2): 439-447.
- [4] WANHG Z J, ZHAO W J, DU W H, et al. Data-driven fault diagnosis method based on the conversion of erosion operation signals into images and convolutional neural network. *Process Safety and Environmental Protection*, 2021, 149(12): 591-601.
- [5] KUMAR A, VASHISHTHA G, GANDHI C P, et al. Novel convolutional neural network (NCNN) for the diagnosis of bearing defects in rotary machinery. *IEEE Transactions on Instrumentation and Measurement*, 2021, 70: 1-10.
- [6] MAO Wentao, TIAN Siyu, DOU Zhi, et al. A new deep transfer learning-based online detection method of rolling bearing early fault. *Acta Automatica Sinica*, 2020, 1-13. <https://doi.org/10.16383/j.aas.c190593>.
(毛文涛, 田思雨, 窦智, 等. 一种基于深度迁移学习的滚动轴承早期故障在线检测方法. *自动化学报*, 2020, 1-13, <https://doi.org/10.16383/j.aas.c190593>.)
- [7] YANG Ruishuang, NING Qian, LEI Yinjie, et al. Fault Diagnosis for rolling Bearings Based on GCNN-LightGBM. *Bearing*, 2021, 6: 44-49.
(杨瑞双, 宁芊, 雷印杰, 等. 基于改进卷积神经网络及LightGBM的滚动轴承故障诊断. *轴承*, 2021, 6: 44-49.)
- [8] JANSSENS O, SLAVKOVIKJ V, VERVISCH B, et al. Convolutional neural network based fault detection for rotating machinery. *Journal of Sound and Vibration*, 2016, 377: 331-345.
- [9] HOANG D T, KANG H J. Rolling element bearing fault diagnosis using convolutional neural network and vibration image. *Cognitive Systems Research*, 2019, 53: 42-50.
- [10] WANG H, LI S, SONG L, et al. A novel convolutional neural network based fault recognition method via image fusion of multi-vibration-signals. *Computers in Industry*, 2019, 105(6): 182-190.
- [11] AFRASIABI S, AFRASIABI M, PARANG B, et al. Real-Time Bearing Fault Diagnosis of Induction Motors with Accelerated Deep Learning Approach. *2019 10th International Power Electronics, Drive Systems and Technologies Conference (PEDSTC)*, 2019.
- [12] XU Yao, LU Shuan, HAN Yinghua. Abnormal behavior detection of electric user based on CNN-GS-SVM classifier. *Control Engineering of China*, 2020, 1-10. <https://doi.org/10.14107/j.cnki.kzgc.20190655>.
(徐瑶, 李栓, 韩英华. 基于CNN-GS-SVM的用户异常用电行为检测. *控制工程*, 2020, 1-10. <https://doi.org/10.14107/j.cnki.kzgc.20190655>)
- [13] YU Zhifeng, XIONG Bangshu, XIONG Tianyang, et al. LI Xinmin. Fault diagnosis of helicopter bearing based on VMD-CWT and improved CNN. *Journal of Aerospace Power*, 2021, 36(5): 948-958.
(余志峰, 熊邦书, 熊天阳, 等. 基于VMD-CWT和改进CNN的直升机轴承故障诊断. *航空动力学报*, 2021, 36(5): 948-958)
- [14] XU J, MA L H, ZHANG W, et al. An improved hybrid CNN-SVM based method for bearing fault diagnosis under noisy environment. *2019 Chinese Control And Decision Conference (CCDC)*, IEEE, 2019: 4660-4665.
- [15] JIA X, XIAO B, ZHAO Z, et al. Bearing fault diagnosis method based on CNN-LightGBM. *IOP Conference Series: Materials Science and Engineering*. IOP Publishing, 2021, 1043(2): 1-12.
- [16] CUI M L, WANG Y Q, LIN X S, et al. Fault diagnosis of rolling bearings based on an improved stack autoencoder and support vector machine. *IEEE Sensors Journal*, 2020, 21(4): 4927-4937.
- [17] LIN M, CHEN Q, YAN S C. Network in network. *Computer Science*, 2013, arXiv: 1312. 4400
- [18] KE G, MENG Q, FINLEY T, et al. LightGBM: A highly efficient gradient boosting decision tree. *Advances in neural information processing systems*, 2017, 30: 3146-3154.
- [19] Case Western Reserve University Bearing Data Center Website (<http://csegroups.case.edu/bearingdatacenter/home>)
- [20] CHRISTIAN L, JAMES K K, DETMAR Z, et al. Condition monitoring of bearing damage in electromechanical drive systems by using motor current signals of electric motors: A benchmark data set for data-driven classification. *IPHM Society European Conference*, 2016, 30(1):1-17.
- [21] JIA S, HU F, FENG X. Deep Convolutional Auto-encoders Based Fault Diagnosis for Diesel Generator Set. *2019 IEEE 2nd International Conference on Information Communication and Signal Processing (ICICSP)*, 2019: 29-33.
- [22] ZHANG Y, JI J, MA B. Reciprocating compressor fault diagnosis using an optimized convolutional deep belief network. *Journal of Vibration and Control*, 2020, 26(17-18): 1538-1548.
- [23] ZHAO X, JIA M, LIU Z. Semisupervised graph convolution deep belief network for fault diagnosis of electromechanical system with limited labeled data. *IEEE Transactions on Industrial Informatics*, 2020, 17(8): 5450-5460.

作者简介:

张思源 硕士研究生, 目前研究方向为故障诊断与容错控制, E-mail: zsyuan1061@163.com;

纪洪泉 副教授, 硕士生导师, 目前研究方向为数据驱动的工业过程异常监测和早期故障诊断, E-mail: jihq18@sdust.edu.cn;

刘洋 研究助理, 目前研究方向为故障诊断、随机系统、分布式系统与轨迹跟踪等, E-mail: y.liu6@lboro.ac.uk.