

# 基于孪生卷积网络的高速列车转向架故障辨识

吴昀璞, 金炜东, 任俊箫

(西南交通大学电气工程学院, 四川 成都 610031)

**摘要:** 高速列车转向架关键构件的性能退化与故障会危及列车运行安全。针对高速列车故障辨识中面临的监测数据高维度和样本稀缺问题, 提出一种基于孪生卷积神经网络的转向架故障类型辨识方法, 利用深度残差一维卷积网络进行多通道振动监测信号的特征提取与融合, 使用孪生结构获得基于特征距离的样本相似度, 依据支撑集典型数据样本进行故障类型辨识。实验结果表明, 该方法可以在仅有少量样本的情况下, 实现高速列车转向架多种故障类型辨识, 提高了在小样本数据下的故障类型识别准确率。

**关键词:** 高速列车转向架; 故障辨识; 小样本学习; 孪生网络

中图分类号: TP277

文献标识码: A

文章编号: 1004-731X (2019) 11-2562-07

DOI: 10.16182/j.issn1004731x.joss.19-FZ0281

## Fault Identification of High-Speed Train Bogie Based on Siamese Convolutional Neural Network

Wu Yunpu, Jin Weidong, Ren Junxiao

(School of Electrical Engineering, Southwest Jiaotong University, Chengdu 610031, China)

**Abstract:** The performance degradation and failure of high-speed train bogie components will threaten the operation security of train. This paper proposes a fault type identification method based on siamese convolutional neural network to address the scarcity of data and the high-dimension of monitoring signals. Deep residual network with one-dimension convolution layers is employed for features extraction and fusion of vibration signals from multiple sensors. The siamese structure is employed to obtain the similarities between samples. Fault types are identified by ranking similarities in the support set. The experimental results show that the proposed method can identify the fault types with only a few training samples and improve the accuracy compared with conventional methods.

**Keywords:** high-speed train bogie; fault identification; few-shot learning; siamese network

## 引言

高速列车作为一种在世界范围内的快速发展的现代交通方式, 具有快捷、高效、环保等优势。随着高速列车的高速度、高密度、跨区域的

开行, 高速列车的安全运行及保障技术已经成为领域研究关注的首要问题。高速列车在长期运行中, 车辆关键部件的性能参数会发生改变, 从而会对高速列车安全运行造成威胁。

深度神经网络作为近年来兴起的一种高效的深度学习模型, 已在包括计算机视觉, 自然语言处理, 自动驾驶等诸多应用领域内取得巨大成功<sup>[1-2]</sup>。对于振动信号分析识别, 深度学习架构不仅可以应对高维度数据, 还可以很大程度上摆脱对专家经验



收稿日期: 2019-05-19 修回日期: 2019-07-04;  
作者简介: 吴昀璞(1991-), 男, 江苏, 博士生, 研究方向为深度学习, 故障诊断等; 金炜东(1959-), 男, 安徽, 博士, 教授, 博导, 研究方向为智能信息处理, 系统仿真与优化方法等; 任俊箫(1991-), 男, 四川, 博士生, 研究方向为故障诊断等。

http: www.china-simulation.com

• 2562 •

和领域知识的依赖<sup>[3]</sup>。与此同时,已有学者将深度神经网络应用于高速列车故障监测<sup>[4]</sup>,文献[5]使用自动编码器提取转向架故障特征,而后结合深度神经网络故障进行分类,文献[6]使用一维卷积神经网络对高速列车的轮对故障进行识别。文献[7]使用多视角架构,从尺度视角、分量视角、通道视角综合考虑,实现高速列车转向架故障部件定位。然而,以上研究通常需要大量的有标注监测数据,且高速列车故障监测系统通常包含多个传感器通道,因此,实际应用中,数据维度大且故障样本少成为了深度神经网络等机器学习模型面临的首要问题。

小样本学习(Few-shot learning)是元学习(Meta learning)在监督学习领域的一个研究方向<sup>[8]</sup>,小样本学习希望模型可以通过对少量的数据有效学习,获得对大量样本的判别能力,正如人类非常擅长通过极少量的样本识别一类物体。在图像识别领域,小样本学习已经受到了许多关注<sup>[9]</sup>,文献[10]通过层级贝叶斯模型对图片概念学习实现视觉目标分类,文献[11]使用知识迁移的方法对新的视觉目标进行分类。随着近年来对深度神经网络的研究的深入, Gregory Koch 等<sup>[12]</sup>提出使用孪生网络(Siamese Network)进行单样本图片识别,利用图片特征相似性排序,实现小样本下的图片分类与识别。然而,小样本学习在信号模式识别等领域的研究还较少,特别是对于高速列车故障监测等样本稀缺的场景,还未见到相关研究。

针对高速列车转向架故障辨识的样本数据稀缺问题,本文提出一种基于孪生卷积神经网络的转向架故障辨识方法,利用深度残差一维卷积网络进行多通道振动监测信号的特征提取与融合,使用孪生结构获得基于特征距离的样本相似度,依据支撑集典型数据样本进行故障类型辨识,可以在仅有少量样本的情况下,实现高速列车转向架多种故障类型判别,对于保证高速列车安全高效运行具有重要的实际意义。

## 1 高速列车转向架状态监测

高速列车转向架是连接车体和轨道的唯一构

件,如图 1 所示,转向架系统中的悬挂部件中会出现诸如橡胶节点老化、减振器漏油、空簧失气以及轴箱弹簧断裂等问题,这些故障将危及行车安全,通过振动信号监测实现高速列车关键部件的故障诊断是亟待解决的问题。高速列车的振动监测信号的传感器通道数量多,各通道信号间还存在耦合,包括轮轨接触力,摩擦力以及悬挂系统间的相互作用。高速列车的运行工况还受到包括环境、负载等在内的诸多影响因素的作用<sup>[13-14]</sup>,因此,高速列车监测信号分析不仅需要处理高维度和高复杂度,还需要应对诸多不确定因素。




图 1 高速列车转向架  
Fig. 1 Structure of high-speed train bogie

对于基于机器学习等数据驱动的方法而言,通常要求数据完备且能代表目标域的总体分布<sup>[15]</sup>,而对于高速列车系统而言,通常很难取得完备的转向架故障样本数据,如图 2 所示。

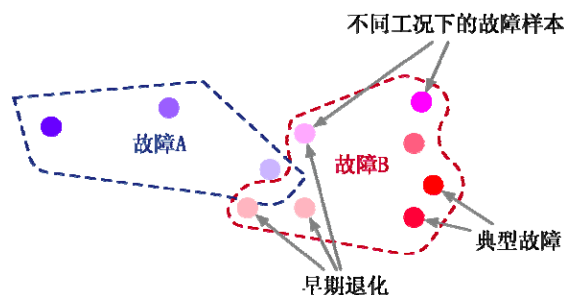


图 2 故障数据样本  
Fig. 2 Data samples of faults

主要体现在 3 个方面:(1) 故障样本总量较少。由于故障类型较多而故障发生较少,每类故障的数据就更加稀缺,以至于不足以为故障辨识模型的拟合提供足够的数据;(2) 故障程度不同。由于故障发生时的严重程度不一,导致标注样本较为稀疏,会引起故障辨识模型的决策边界的偏差;(3) 影响因素

多变。同一类故障发生时的外部影响因素,包括运行速度,负载,线路等,都有很大不同,故障数据的特征也会在外在因素的作用下发生一定程度上的变化,因此要求故障辨识模型具有较强的泛化性能。

## 2 孪生网络

孪生网络结构最初用于解决签名验证问题<sup>[16]</sup>, Gregory Koch 等提出将孪生网络用于解决图片识别中的单样本学习问题<sup>[12]</sup>。孪生网络通过有监督的方式训练网络参数,然后重用网络所提取的特征进行单样本(one-shot)与小样本学习。孪生网络结构通常包含两个或多个相同的子网络,其中,子网络间的权重是共享的,子网络所实现的特征映射函数也是相同的,因此,即使输入不同的子网络,相似度较高的样本也将被网络映射到相近的特征空间。

此外,该结构还可以极大的减少网络参数与训练负担。子网络的输出是样本的深层特征向量  $\mathbf{h}_1 = \{a_1, a_2, \dots, a_n\}$ ,  $\mathbf{h}_2 = \{b_1, b_2, \dots, b_n\}$ , 通过定义样本特征间的距离函数  $L_{\text{distance}}(\mathbf{h}_1, \mathbf{h}_2)$ , 孪生网络可以得到输入样本间的距离信息(相似度/差异度),也因此可以用有监督的方法对整个网络进行训练。

基于孪生网络的单样本学习或小样本学习过程中,每个类别中有单个或少量样本。训练时,通过组合的方式构造不同的成对样本,输入网络进行训练,在最后一层通过样本对的特征距离判断是否属于同一个类,并产生对应的概率分布。因为训练输入的标注数据不再是{样本,类别},而是{样本 A, 样本 B, 是否同类别},因此,对于一个有  $N$  个样本的数据训练集而言,通过样本结对组合后,不同样本可以构成  $N(N-1)$  个组合,将极大的增加训练集样本数量。在预测阶段,孪生网络处理测试样本和支撑集之间每一个样本对,最终预测结果为支撑集上概率最高的类别。孪生网络的主要优点在于:

(1) 可以通过少量样本获取到多类别样本间的共通(generic)特征,并用于预测样本类别;

(2) 可以通过结对组合样本的方法,使用普通的网络与优化方法来进行模型的有监督训练;

(3) 基于深度学习架构,可以提供不依赖于领域知识的小样本学习方法。

## 3 基于孪生卷积神经网络的转向架故障辨识

为将孪生网络应用于多通道信号模式识别,本文采取一种孪生残差卷积神经网络结构(Siamese Residual Convolutional Neural Network, Siam-Res CNN)来实现故障类型辨识,如图3所示。

本文使用一维卷积网络进行多通道振动监测信号的特征提取与融合,多通道卷积层通过可训练的卷积核,对各通道特征进行加权,通过网络训练学习到的核参数对应学习到的多通道的融合权重,因此,使用多通道卷积神经网络等效于自适应权重特征融合<sup>[4]</sup>。此外,本文引入深度残差结构以提升对信号特征提取能力。残差结构是一种用于应对深层神经网络梯度消失的神经网络结构,最近的研究表明其还可以提升信息在神经网络中的前向以及反向传播<sup>[17]</sup>。残差连接可以视为一种跨接(skip connection),通过绕过一些非线性变换以实现特征映射,可以视为根据输入学习的残差函数而非原始函数。残差连接结构可以表示为:

$$x_l = H_l(x_{l-1}) + x_{l-1} \quad (1)$$

式中:  $x_l$  和  $x_{l-1}$  为第  $l$  个神经元的输入和输出;  $H_l(\cdot)$  为相应的残差函数。

本文所采用残差卷积网络作为孪生结构子网络,残差子网络包含 3 级结构,每级包含 2 个残差连接结构。原始残差网络中,为获得图片数据的深层特征,采取了卷积核数量随网络深度增加的模型设置策略,考虑到振动信号与图像信号的差异性,以及孪生网络的特异性,本文采取卷积核数量随模型深度递减的策略,即 3 个层级卷积核数量随层级加深而递减,这主要是因为:(1) 图像识别的卷积核递增策略主要是为了获得细部特征,而振动信号,特别是包含周期性的振动信号,其信号特征往往不限于局部尺度空间内<sup>[18]</sup>;(2) 可以压缩最终特征空间,降低孪生子网络输出特征向量维度,降低目标损失函数的优化难度。

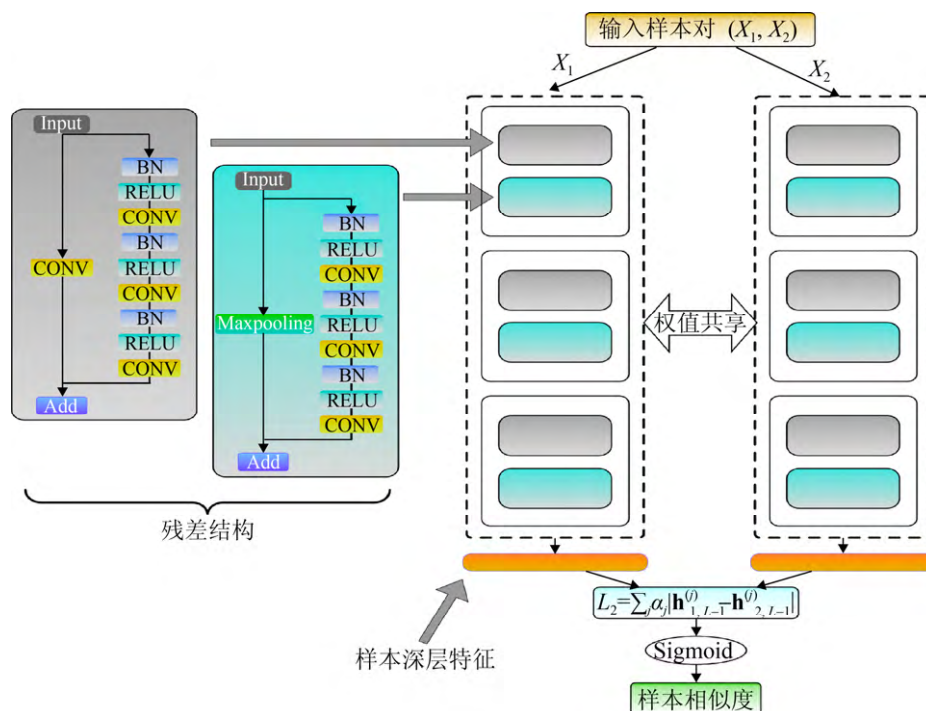


图3 孪生残差卷积神经网络结构

Fig. 3 Structure of siamese residual convolutional neural network

对于子网络的输出特征向量，本文采用  $L_2$  距离作为样本特征相似度的度量指标：

$$L_2 = \sum_j \alpha_j \left| \mathbf{h}_{1,L-1}^{(j)} - \mathbf{h}_{2,L-1}^{(j)} \right| \quad (2)$$

此外，使用与文献[12]相同的 Sigmoid 激活函数与二分类交叉熵作为目标损失函数。模型的拟合与故障辨识主要流程如下：

(1) 随机数据结对。对总共含有  $N$  个监测数据样本的数据集(包含正常运行样本与故障样本)进行随机结对组合, 将标注样本集合由{样本 A, 类别}形式构造为{样本 A, 样本 B, 是否同类别}的形式, 相同类别样本标注为 0, 不同样本标注为 1, 通过从样本池持续随机采样的方式, 为模型拟合提供训练数据。

(2) 模型拟合。使用  $L_2$  距离与 Sigmoid 激活函数构成孪生网络的输出，对应结对样本的类别标注，应用二分类交叉熵作为模型的损失函数。

(3) 故障类别辨识。选取典型样本集合构成支撑集  $S = \{s_1, s_2, \dots, s_m\}$ , 对于模型的输入样本  $x$ , 将其与支撑集样本顺序结对, 构成待测集

$S_t = \{(x, s_1), (x, s_2), \dots, (x, s_m)\}$  , 通过将待测集输入孪生网络, 可以获得表示样本相似度的预测概率向量  $\mathbf{p} = \{p_1, p_2, \dots, p_m\}$  , 预测概率向量中最大的分量所对应的支持集样本的所属类别, 即为模型对于样本  $x$  所属类别的预测结果  $C^* = \arg \max_c (p)$ 。

## 4 实验分析

实验数据来自西南交通大学牵引动力国家重点实验室高速列车转向架仿真平台,该平台基于多体动力学分析软件 Simpack 建立 CRH380A 动车组车辆系统的动力学模型,模型针对轮轨接触几何非线性、轮轨蠕滑非线性和非线性悬挂等建立,仿真实验采用高铁实测轨道激励谱。监测信号共包含 58 个传感器通道,包括车体、构架、轴箱上各个部位横向、纵向和垂向振动加速度和车体、构架、轮对、一系、二系各部位 3 个方向的振动位移,采样频率为 243 Hz。实验涉及的转向架工况主要包括正常运行状态、空气弹簧失气、横向减振器故障、抗蛇行减振器故障,轴箱垂直减震器故障和轴箱弹簧故障,如图 4 所示。






图 4 转向架主要故障部件  
Fig. 4 Main fault components of bogie

在本实验中,我们采用时域滑动窗口采样的方法获得故障样本,设置滑动长度等于采样窗口宽度,以保证样本间无重叠,样本长度 1 s,考虑到工程实际中故障样本的稀缺性,实验中仅使用少量样本进行模型训练拟合,包括正常运行状态和五类故障情况,从获得的样本中,每类随机抽取  $n(n=\{5, 10\})$  个有标注样本构建大小为  $6n$  的训练集(train set)。为了验证模型的性能,每类随机抽取  $s=10$  个有标注样本作为支撑集(support set),每类随机抽取  $t=500$  个样本作为测试集(test set)评价模型性能。需要说明的是,在实际应用中,支撑集样本可以通过专家知识筛选的每类故障的典型样本,以提高辨识准确率,本实验中为了验证模型性能,从与训练集不相交的数据池里随机抽取以构成支撑集。

对于识别准确程度常用的评价指标包括准确率(Accuracy),精确率(Precision),召回率(Recall)和 F1 值(F1-score)。考虑到对于正常状态以及每类故障的识别,有可能出现的 4 种结果分别是:正类被预测为正类(True positive, TP);负类被预测成正

类(False positive, FP);负类被预测成负类(True negative, TN);正类被预测成负类(False negative, FN)。因此,以上评价指标的其计算方法分别为:

$$\text{Accuracy} = \frac{TP}{N_A} \quad (3)$$

式中:  $N_A$  为该类总样本数。

$$\text{Precision} = \frac{TP}{TP + FP} \quad (4)$$

$$\text{Recall} = \frac{TP}{TP + FN} \quad (5)$$

$$\text{F-score}(\beta) = \frac{(1 + \beta^2)TP}{(1 + \beta^2)TP + \beta^2FP + FN} \quad (6)$$

式中:  $\beta$  通常取 1, 即 F1-score。

考虑到本文针对多类故障辨识,我们采用宏平均的方法获得以上评价指标的均值,对于  $n$  类辨识目标,若  $B(*)$  为某一评价指标,则其宏平均为:

$$B_{\text{macro}} = \frac{1}{n} \sum_{\lambda=1}^n B(TP_{\lambda}, FP_{\lambda}, TP_{\lambda}, FN_{\lambda}) \quad (7)$$

为了验证本文所提出的 Siam-ResCNN 在高速列车转向架故障辨识的有效性,我们比较了 Siam-ResCNN, k 近邻(k-Nearest Neighbor, k-NN)方法与原始孪生网络<sup>[12]</sup>在转向架故障类型识别上的效果,需要注意的是,对于 k-NN 方法,我们这里仅选择最近邻样本(即  $k=1$ )。对于每种方法,本文分别在每类  $n=\{5, 10\}$  个样本的训练集下进行 10 次模型训练拟合,然后在测试集上检验模型性能,每次训练时,实验训练集都基于随机抽取,模型在测试集上的性能评价指标的均值及相应标准差见表 1 和图 5。

表 1 故障识别性能  
Tab. 1 Performance of fault identification

方法( $n$ 为每类样本数)	准确率(Accuracy)	精确率(Precision)	召回率(Recall)	F1 值(F1 score)
k-NN ( $n=5$ )	21.73 ( $\sigma=1.21$ )	32.89 ( $\sigma=1.07$ )	21.73 ( $\sigma=1.21$ )	21.81 ( $\sigma=1.48$ )
k-NN ( $n=10$ )	23.29 ( $\sigma=0.76$ )	33.25 ( $\sigma=1.10$ )	23.29 ( $\sigma=0.76$ )	23.76 ( $\sigma=0.54$ )
Siamese Network ( $n=5$ )	27.25 ( $\sigma=2.01$ )	26.30 ( $\sigma=3.06$ )	27.25 ( $\sigma=2.01$ )	25.45 ( $\sigma=3.42$ )
Siamese Network ( $n=10$ )	43.90 ( $\sigma=3.52$ )	44.65 ( $\sigma=3.22$ )	43.90 ( $\sigma=3.52$ )	42.12 ( $\sigma=3.99$ )
Siam-ResCNN ( $n=5$ )	69.35 ( $\sigma=4.57$ )	69.83 ( $\sigma=5.69$ )	69.35 ( $\sigma=4.57$ )	67.81 ( $\sigma=5.02$ )
Siam-ResCNN ( $n=10$ )	89.47 ( $\sigma=6.15$ )	89.94 ( $\sigma=5.95$ )	89.47 ( $\sigma=6.15$ )	89.24 ( $\sigma=6.40$ )

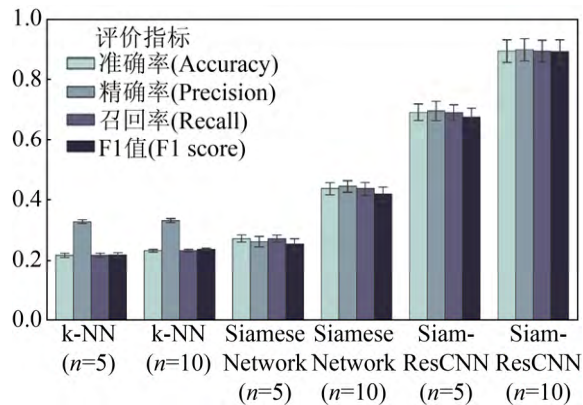


图 5 故障识别性能比较

Fig. 5 Comparisons of fault identification performance

通过实验可以看到, k-NN 在  $n=\{5,10\}$  的 2 种实验条件设置下, 识别准确率分别为 21.73% 和 23.29%, 仅略高于随机猜测的预测结果(注: 6 类分类的随机猜测准确率为 16.67%), 而原始孪生网络在  $n=10$  的实验条件下的辨识准确率也仅达到 43.90%, 而本文提出的 Siam-ResCNN 架构分别获得了 69.35% ( $n=5$ ) 和 89.47% ( $n=10$ ) 的故障类型诊断准确率。这意味着 Siam-ResCNN 具有较强的信号特征提取与识别能力, 可以大幅降低在实际应用中获取故障数据的成本。

## 5 结论

本文提出一种基于孪生卷积神经网络的高速列车转向架故障类型辨识模型, 针对高速列车故障辨识中的样本数据稀缺问题, 利用深度残差卷积网络进行多通道振动监测信号的特征提取与融合, 使用孪生结构获得基于特征距离的样本相似度, 依据支撑集典型数据样本进行故障类型辨识。实验结果表明, 该方法可以在仅有少量样本的情况下, 实现高速列车转向架多种故障类型判别, 提高了在小样本数据下的故障类型识别准确率, 该模型具有较好的可实现性和推广性, 为实现高速列车转向架的快速准确的故障诊断提供了一种可行方案, 对于保证高速列车安全高效运行具有重要的实际意义。

## 参考文献:

[1] LeCun Y, Bengio Y, Hinton G. Deep learning[J]. Nature

(S1476-4687), 2015, 521(7553): 436.

- [2] Schmidhuber J. Deep learning in neural networks: An overview [J]. Neural networks (S1879-2782), 2015, 61: 85-117.
- [3] Liu R, Yang B, Zio E, et al. Artificial intelligence for fault diagnosis of rotating machinery: A review[J]. Mechanical Systems and Signal Processing (S1096-1216), 2018, 108: 33-47.
- [4] 吴昀璞, 金炜东, 黄颖坤. 基于多域融合 CNN 的高速列车转向架故障检测[J]. 系统仿真学报, 2018, 30(11): 4492-4497.  
Wu Yunpu, Jin Weidong, Huang Yingkun. High Speed Train Bogie Fault Diagnosis Based on Multi-domain Fusion CNN[J]. Journal of System Simulation, 2018, 30(11): 4492-4497.
- [5] Hu H, Tang B, Gong X, et al. Intelligent fault diagnosis of the high-speed train with big data based on deep neural networks[J]. IEEE Transactions on Industrial Informatics (S1941-0050), 2017, 13(4): 2106-2116.
- [6] Peng D, Liu Z, Wang H, et al. A Novel Deeper One-Dimensional CNN With Residual Learning for Fault Diagnosis of Wheelset Bearings in High-Speed Trains[J]. IEEE Access (S2169-3536), 2019, 7: 10278-10293.
- [7] Wu Y, Jin W, Ren J, et al. A multi-perspective architecture for high-speed train fault diagnosis based on variational mode decomposition and enhanced multi-scale structure[J/OL]. Applied Intelligence (S1573-7497), 2019. <https://link.springer.com/article/10.1007/s10489-019-01483-8>.
- [8] Wang Y, Yao Q. Generalizing from a Few Examples: A Survey on Few-Shot Learning [J]. arXiv preprint (S2331-8422) arXiv: 1904.05046, 2019.
- [9] Lake B, Salakhutdinov R, Gross J, et al. One shot learning of simple visual concepts[C]. Proceedings of the Annual Meeting of the Cognitive Science Society. Boston, USA: Curran Associates, Inc, 2011.
- [10] Lake B M, Salakhutdinov R R, Tenenbaum J. One-shot learning by inverting a compositional causal process[C]. Advances in neural information processing systems. Lake Tahoe, USA: Curran Associates, Inc., 2013: 2526-2534.
- [11] Mao J, Wei X, Yang Y, et al. Learning like a child: Fast novel visual concept learning from sentence descriptions of images[C]. Proceedings of the IEEE international conference on computer vision. Santiago, Chile: IEEE, 2015: 2533-2541.
- [12] Koch G, Zemel R, Salakhutdinov R. Siamese neural networks for one-shot image recognition[C]. ICML deep learning workshop. Lille, France: ICML, 2015: 2.

- [13] Latorre Iglesias E, Thompson D J, Smith M, et al. Anechoic wind tunnel tests on high-speed train bogie aerodynamic noise [J]. International Journal of Rail Transportation (S2324-8386), 2017, 5(2): 87-109.
- [14] Lu Y, Xiang P, Dong P, et al. Analysis of the effects of vibration modes on fatigue damage in high-speed train bogie frames [J]. Engineering Failure Analysis (S1350-6307), 2018, 89: 222-241.
- [15] Haixiang G, Yijing L, Shang J, et al. Learning from class-imbalanced data: Review of methods and applications[J]. Expert Systems with Applications (S1873-6793), 2017, 73: 220-239.
- [16] Bromley J, Guyon I, LeCun Y, et al. Signature verification using a " siamese" time delay neural network[C]. Advances in neural information processing systems. London, England: MIT press, 1994: 737-744.
- [17] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]. Proceedings of the IEEE conference on computer vision and pattern recognition. Las Vegas, USA: IEEE, 2016: 770-778.
- [18] Zhang W, Li C, Peng G, et al. A deep convolutional neural network with new training methods for bearing fault diagnosis under noisy environment and different working load[J]. Mechanical Systems and Signal Processing (S1096-1216), 2018, 100: 439-453.